

# [SNU DS<sup>2</sup>] Data Mining - Linear Algebra

March 22, 2018

## 1. 선형 변환과 행렬

- 함수  $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$ 이 모든  $a, b \in \mathbb{R}, x, y \in \mathbb{R}^m$ 에 대해 다음 성질을 만족하면  $f$ 를 **선형 변환**이라고 한다.

$$f(a \cdot x + b \cdot y) = a \cdot f(x) + b \cdot f(y)$$

- 임의의  $n \times m$  행렬  $A$ 에 대해, 함수  $f_A : \mathbb{R}^m \rightarrow \mathbb{R}^n$ 를  $f_A(x) = A \cdot x$ 로 정의 하면  $f_A$ 는 선형 변환이 된다.
- 임의의 선형 변환  $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$ 는  $f = f_A$ 를 만족하는  $n \times m$  행렬  $A$ 가 존재한다.
- 따라서, 행렬은 선형 변환 함수와 동일하게 생각할 수 있다.
- ex) 행렬의 곱셈은 교환이 안된다 = 함수의 합성은 교환이 안된다.

## 2. 행렬식 (determinant)

- 정사각 행렬 : 행의 개수와 열의 개수가 일치하는 행렬.
- 정사각 행렬  $A$ 의 행렬식은  $\det(A)$  혹은  $|A|$ 로 표기한다.
- $2 \times 2$  행렬  $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ 의 행렬식

$$\det(A) = ad - bc$$

- $m \times m$  행렬  $A$ 의 행렬식  $\det(A)$ 의 대의적 정의 :  
 $\mathbb{R}^m$  상의 집합  $V$ 에 대해

$$\frac{\{y : y = Ax \text{ for } x \in V\} \text{의 부피}}{V \text{의 부피}}$$

### 3. 선형 독립, 선형 종속, 기저

- 벡터  $v_1, \dots, v_m \in \mathbb{R}^n$ 이 다음 식을 만족하면 **선형 종속 (linearly dependent)** 이라 한다.  
임의의 실수  $a_1, \dots, a_m \in \mathbb{R}$ 이 존재해서 어떤  $1 \leq j \leq m$ 에 대해  $a_j \neq 0$ 이 성립하며

$$\sum_{j=1}^m a_j \cdot v_j = 0$$

이 성립한다.

- 다시 말해, 어떤 벡터  $v_j, 1 \leq j \leq m$ 이 다른 벡터의 선형 결합으로 표현되면 선형 종속이라고 한다.
- 벡터  $v_1, \dots, v_m \in \mathbb{R}^n$ 이 선형 종속이 아닌 경우 **선형 독립 (linearly independent)** 이라고 한다.
- $m \times m$  정사각 행렬  $A$ 에 대해 다음이 성립한다.
  - 모든  $x \in \mathbb{R}^m \neq 0$ 에 대해  $A \cdot x \neq 0$ 이 성립한다  
 $\leftrightarrow A$ 의 모든 열벡터는 선형 독립이다  $\leftrightarrow \det(A) \neq 0$
  - 어떤  $x \in \mathbb{R}^m \neq 0$ 가 존재해서  $A \cdot x = 0$ 이 성립한다  
 $\leftrightarrow A$ 의 모든 열벡터는 선형 종속이다  $\leftrightarrow \det(A) = 0$
- $m$ 차원 벡터  $x_1, \dots, x_n$ 이 모든 벡터  $y \in \mathbb{R}^m$ 을 선형으로 표현 가능한 경우, 즉 어떤 상수  $a_1, \dots, a_m$ 이 존재해서  $y = \sum_{j=1}^m a_j x_j$ 가 성립하는 경우  $m$ 차원 벡터  $x_1, \dots, x_n$ 이  $\mathbb{R}^m$ 을 **span** 한다고 한다.
- $\mathbb{R}^m$ 을 span하는  $m$ 차원 벡터  $x_1, \dots, x_n$ 이 선형 독립인 경우,  $x_1, \dots, x_n$ 을 **기저 (basis)** 라고 하며  $m = n$ 이 성립한다.

### 4. 벡터의 내적 (dot product) 및 수직관계

- $x = (x_1, \dots, x_m)'$ ,  $y = (y_1, \dots, y_m)'$ 를  $m$ 차원 벡터라 하자.
- 차원이 같은 두 벡터 간의 내적은 다음과 같이 정의된다.

$$x \cdot y = x' y = \sum_{j=1}^m x_j \cdot y_j$$

- 벡터의 크기 (norm)은 다음과 같이 정의한다.

$$|x| = \sqrt{\sum_{j=1}^m x_j^2} = \sqrt{x \cdot x}$$

- 두 벡터  $x, y$  간의 사잇각을  $\theta$ 라 하면 다음 식이 성립한다.

$$x \cdot y = |x| \cdot |y| \cdot \cos(\theta)$$

- 두 벡터  $x, y$ 가 수직관계에 있는 경우, 즉 사잇각이 90도인 경우,  $\cos 90 = 0$ 이므로  $x \cdot y = 0$ 이 성립한다.
- 벡터  $x_1, \dots, x_n$ 이 직교한다(orthogonal)는 것은 이들 중 아무렇게나 두 순서쌍을 뽑아도 두 벡터가 수직관계에 있다는 것을 의미한다.
- 직교하는 벡터  $x_1, \dots, x_n$ 은 선형 독립이다.
- $m$ 차원 벡터  $x_1, \dots, x_m$ 이 직교하는 경우 이들은  $m$ 차원 기저(basis)를 이룬다.
- 벡터  $x_1, \dots, x_n$ 이 orthonormal 한다는 것은 이들이 직교함(orthogonal)과 동시에 이들의 크기가 모두 1임을 의미한다. 가 1 : orthonormal

#### 5. 고유값(eigenvalue)와 고유벡터(eigenvector)

- 임의의  $m \times m$  정사각 행렬  $A$ 에 대해 벡터  $x \in \mathbb{R}^m$ 과 실수  $\lambda$ 가 존재해서  $Ax = \lambda x$ 를 만족하면  $\lambda$ 를 ( $x$ 에 대응되는)  $A$ 의 고유값,  $x$ 를 ( $\lambda$ 에 대응되는)  $A$ 의 고유벡터라고 한다.
- $A$ 가  $m \times m$  대칭행렬인 경우,  $m$ 개의 고유값과 이에 대응되는 고유벡터쌍  $(\lambda_1, e_1), \dots, (\lambda_m, e_m)$ 이 존재하며, 이 때 고유벡터들은 orthonormal하게 선택할 수 있다.
- $m \times m$  대칭행렬  $A$ 의  $m$ 개의 고유값과 이에 대응되는 고유벡터쌍이  $(\lambda_1, e_1), \dots, (\lambda_m, e_m)$ 인 경우, 다음 식이 성립한다 (스펙트럴 분해)

$$A = P \Lambda P' = \lambda_1 e_1 e_1' + \dots + \lambda_m e_m e_m'$$

이 때  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$ ,  $P = [e_1, \dots, e_m]$ 이며, 각 쌍의 순서가 바뀌어도 위 식은 성립한다.

#### 6. 다변량 변수의 분산

- 확률벡터  $X = [X_1, \dots, X_m]$ 의 공분산 행렬은 다음과 같이 정의된다.

$$Cov(X) = \Sigma = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) & \cdots & Cov(X_1, X_m) \\ Cov(X_1, X_2) & Var(X_2) & \cdots & \cdots \\ \vdots & \vdots & \ddots & \vdots \\ Cov(X_m, X_1) & \cdots & \ddots & Var(X_m) \end{bmatrix}$$

- 임의의 벡터  $a = (a_1, \dots, a_m)', b = (b_1, \dots, b_m)'$ 에 대해 다음이 성립한다.

$$Var(a'X) = Var(a_1X_1 + \cdots a_mX_m) = a'\Sigma a$$

$$Cov(a'X, b'X) = a'\Sigma b$$

- 공분산 행렬  $\Sigma$ 는 대칭행렬이며, 따라서 스펙트럴 분해가 가능하다.  $\Sigma$ 의  $m$ 개의 고유값과 이에 대응되는 고유벡터쌍을 고유값의 크기 순으로  $(\lambda_1, a_1), \dots, (\lambda_m, a_m)$ 이라 하자. (즉,  $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_m$ 이 성립).
- $X$ 의 총 변동 =  $Var(X_1) + Var(X_2) + \cdots Var(X_m)$ 이라고 정의하자. 이 때  $X$ 의 총 변동 =  $\lambda_1 + \cdots \lambda_m$ 이 성립한다.

## 7. 주성분 분석

- 주성분 분석의 목적 : 가능한 적은 변수로 기존의 다변량 벡터  $X = [X_1, \dots, X_m]$ 이 설명하는 정보를 최대한 설명하기.
- 주성분의 정의
  - 첫번째 주성분 : 변수들의 전체 분산 중 가장 큰 부분을 설명할 수 있는 선형 결합
  - 두번째 주성분 : 첫번째 주성분과 독립이면서 첫번째 주성분에 의해 설명되지 않은 잔여 분산을 최대한 설명할 수 있는 선형 결합
  - 세번째 주성분 : ...
- (주성분 분석 알고리즘)  $C_1 = a'_1X = a_{11}X_1 + \cdots + a_{m1}X_m, C_2 = a'_2X, \dots, C_m = a'_mX$ 라 하면,  $C_i$ 가  $X$ 의  $i$ 번째 주성분이 되며,  $i$ 번째 주성분의 분산은  $\lambda_i$ 와 동일하다. ( $\rightarrow \lambda_i \geq 0$ )